

Algorithmik zur Optimierung in neuronalen Netzwerken

Gradient Descent und Backpropagation

Tim Hilt

Date: tbd

Hochschule Esslingen — University of Applied Sciences

Supervised Learning

Künstliche Neuronale Netze

Training

- Loss-Funktion

- Gradient Descent

- Backpropagation

Supervised Learning

Machine Learning Workflow

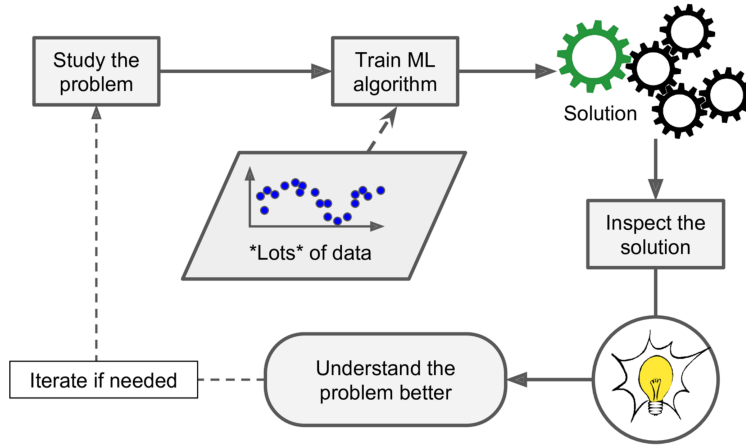


Abbildung 1: Machine Learning Workflow [1]




Abbildung 2: Struktur der Daten bei Supervised Learning [1]





Abbildung 2: Struktur der Daten bei Supervised Learning [1]

Definition Supervised Learning

„In supervised learning, the dataset is the collection of labeled examples $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$. Each element \mathbf{x}_i among N is called a feature vector. A feature vector is a vector in which each dimension $j = 1, \dots, D$ contains a value that describes the example somehow [...]. The goal of a supervised learning algorithm is to use the dataset to produce a model, that takes a feature vector \mathbf{x} as input and outputs information that allow deducing the label \hat{y} for this feature vector.“ [2]

Beispiel: Datensatz für Supervised Learning



- Insgesamt 70000 Bilder
- Bildgröße: 28×28 Pixel
- Abgebildet: Handgeschriebene Ziffern von 0 bis 9
- Quelle: Yann LeCun et al [3]

Beispiel: Datensatz für Supervised Learning



- Insgesamt 70000 Bilder
- Bildgröße: 28×28 Pixel
- Abgebildet: Kleidungsstücke
- Quelle: Zalando Research [4]

Label	Description
0	T-shirt/top
1	Trouser
2	Pullover
3	Dress
4	Coat
5	Sandal
6	Shirt
7	Sneaker
8	Bag
9	Ankle boot

Künstliche Neuronale Netze

Training

Backpropagation

Es werden vier Gleichungen benötigt:

Error im Output-Layer:

Error einzelner Neuronen:

$$\delta_j^L = \frac{\partial C}{\partial a_j^L} \sigma'(z_j^L)$$

Vektorisiert:

$$\delta^L = \nabla_a C \odot \sigma'(z^L)$$

Aufgelöst, wenn MSE benutzt:

$$\delta^L = (a^L - y) \odot \sigma'(z^L)$$

Error im Layer l hinsichtlich Error im nächsten Layer δ^{l+1}

$$\delta^l = \left((w^{l+1})^T \delta^{l+1} \right) \odot \sigma' (z^l)$$

- Rekursive Definition durch Verwendung von δ^l in Abhängigkeit von δ^{l+1}
- Wenn anfangs δ^L in die Gleichung gegeben wird kann der Error rekursiv für jeden vorhergehenden Layer berechnet werden

$$\delta^L = \nabla_a C \odot \sigma' (z^L)$$

$$\delta^l = \left((w^{l+1})^T \delta^{l+1} \right) \odot \sigma' (z^l)$$





$$\frac{\partial C}{\partial b_j^l} = \delta_j^l$$

$$\frac{\partial C}{\partial w_{jk}^l} = a_k^{l-1} \delta_j^l$$

Pass

Fragen?

Literaturverzeichnis

-  GÉRON, Aurélien. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. O'Reilly Media, 2019.
-  BURKOV, Andriy. *The hundred-page machine learning book*. Andriy Burkov Quebec City, Can., 2019.
-  LECUN, Yann; BOTTOU, Léon; BENGIO, Yoshua; HAFFNER, Patrick. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*. 1998, Jg. 86, Nr. 11, S. 2278–2324.
-  XIAO, Han; RASUL, Kashif; VOLLGRAF, Roland. Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms. *arXiv preprint arXiv:1708.07747*. 2017.